

Instituto Politécnico Nacional

Centro de Investigación en Computación (CIC)

Departamento de diplomados y extensión profesional

Curso de Machine Learning

Profesor Alan Badillo Salas

Práctica 301

Clasificación - Medidas de desempeño

Semana 3. Febrero 13, 2026.

1. Introducción

En esta práctica aprenderemos uno de los dos métodos más importantes del aprendizaje supervisado. La clasificación permite construir modelos basados en predecir respuestas categóricas, por ejemplo, cuando se busca entender una característica binaria o multibinaria.

La práctica consiste en construir una matriz de características para entrenar un modelo basado en árboles de decisión y otro en la curva logística para poder generar un vector de predicciones, la cual será comparada con el vector de respuesta real y así poder medir el desempeño del modelo para futuras predicciones.

1.1. Objetivo general

Al finalizar la práctica, el alumno será capaz de construir una matriz de características, un vector de respuesta binaria y construir un modelo de clasificación que prediga el comportamiento de la respuesta mediante predicciones. Así como medir el desempeño del modelo y la precisión de las predicciones para poder interpretar la confianza de dichas predicciones con distintas métricas derivadas de la matriz de confusión.

1.2. Objetivos particulares

Al finalizar la práctica, el alumno será capaz de:

- Construir las características informativas más relevantes para poder predecir una respuesta binaria.
- Construir una matriz de características que contenga la información disponible para la predicción.
- Construir un modelo de clasificación basado en árboles de decisión y la curva logística.
- Visualizar e interpretar las decisiones que alcanza el modelo basado en el árbol de decisión
- Construir el vector de predicción sobre una matriz de características observada
- Construir la matriz de confusión que indique cuántas predicciones fueron correctamente alcanzadas y cuántas fallaron cuándo la respuesta debía ser positiva o negativa
- Visualizar la matriz de confusión
- Construir las métricas de evaluación sobre el desempeño del modelo derivadas de la matriz de confusión

- Responder preguntas sobre la predicción de ciertos valores en las características informativas y comparar la probabilidad de la respuesta real contra la predicción

1.3. Entregables

La práctica tendrá un único entregable que consiste en un documento PDF creado en cualquier editor de texto que soporte incrustación de imágenes como Word, Excel, Power Point, Canvas o Latex y que permita la exportación o impresión al formato PDF. También se aceptarán trabajos hechos a mano siempre y cuando sean legibles y estén escaneados en formato PDF no mayor a 20mb.

Las especificaciones del *Documento de la práctica* son:

- **Portada** - Debe contener el nombre del Instituto Politécnico Nacional, el nombre del Centro de Investigación en Computación (CIC) y el Departamento de diplomados y extensión profesional, así como el logo del IPN a la izquierda y del CIC a la derecha en las esquinas superiores. También deberá decir Curso de Machine Learning y abajo el nombre del profesor, Maestro Alan Badillo Salas y el nombre del alumno (tu nombre). Después pon el nombre de la práctica (por ejemplo, Práctica 101 - Introducción al Machine Learning y las herramientas de trabajo). Hasta abajo deberá contener la fecha de la práctica o la fecha en que se realizó en el formato: Entidad del instituto. Mes día, año (por ejemplo, Ciudad de México, Febrero 1, 2026).
- **Introducción** - Explica en un párrafo de qué trata la práctica.
- **Desarrollo** - En el desarrollo deberás explicar la secuencia lógica de la práctica-
- **Resultados** - En esta sección pega las capturas de pantalla de las gráficas generadas.
- **Conclusiones** - En las conclusiones deberás resumir que se hizo en general, para qué sirve y qué aplicaciones actuales y futuras tiene (por ejemplo, ¿Se puede aplicar a tu trabajo actual? ¿Qué tipo de proyecto será interesante hacer ahora?).

1.4. Evaluación

La práctica tiene un valor de 100 puntos, de los cuales 50 son suficientes para marcarla como entregada, si tiene menos de 50 puntos no será aceptada y tendrá que ser corregida.

- **20 puntos** - La portada tiene todos los elementos
- **10 puntos** - La práctica contine una Introducción razonable

- **10 puntos** - La práctica contine la secuencia lógica de pasos completa y es razonable
- **30 puntos** - La práctica contine los resultados solicitados
- **20 puntos** - La práctica contine conclusiones razonables
- **10 puntos** - La práctica fue entregada antes de la práctica siguiente

En esta práctica se considera un mayor peso a los resultados y las conclusiones, por lo que las conclusiones deben ser precisas sobre lo que se entendió de la práctica.

2. Teoría

El problema de la clasificación es parte de *El problema del aprendizaje no supervisado*. En la clasificación se exige que la respuesta sea categórica, para determinar una de las posibles categorías, la forma más simple es suponer una característica binaria o multibinaria (muchas respuestas binarias que predicen cada una si pertenece a una categoría específica la respuesta).

Construcción de la matriz de características

Supongamos que tenemos las características informativas $x_1, x_2, \dots, x_k$, entonces la matriz $X = [x_1|x_2|\dots|x_k]$ representa matriz de características.

```
X = pandas.DataFrame([x1, x2, ..., xk]).T
```

Construcción del vector de respuesta

```
y = <dataframe>["<característica de respuesta>"]
```

Modelo de clasificación por árbol de decisión

```
from sklearn.tree import DecisionTreeClassifier

modelo = DecisionTreeClassifier(
    max_depth=<L>
)
```

Modelo de clasificación por curva logística

```
from sklearn.linear_model import LogisticRegression

modelo = LogisticRegression()
```

Ajustar el modelo de clasificación a los datos observados

```
modelo.fit(X, y)
```

Gráficar el árbol de decisión

```
from sklearn.tree import plot_tree
from matplotlib import pyplot

figure, axis = pyplot.subplots(figsize=(20, 20))

plot_tree(modelo, ax=axis)

pyplot.show()
```

Construir el vector de predicción del modelo

```
yp = modelo.predict(X)
```

Recuperar los valores de la matriz de confusión

```
from sklearn.metrics import confusion_matrix

tn, fp, fn, tp = confusion_matrix(y, yp)
```

Visualizar la matriz de confusión

```
seaborn.heatmap([
    [tn, fp],
    [fn, tp],
], cmap="coolwarm")
```

Construir las metricas de evaluación o desempeño del modelo

```
# La precision para decir que tan verdadera es la prediccionQ
p = tp / (tp + fp)
# La sensibilidad para determinar que tanta verdad se captura
s = tp / (tp + fn)
# El factor F1 para determinar el balance
# entre precision y sensibilidad
```

```

f1 = 2 * (p * s) / (p + s)
# La especificidad para determinar que tanta falsedad se captura
e = tn / (tn + fp)
# La exactitud para determinar que tanto
# se captura en la diagonal
a = (tp + tn) / (tp + tn + fn + fp)

pandas.DataFrame({
    "accuracy": [a],
    "Precision": [p],
    "Sensitivity": [s],
    "Specificity": [e],
    "f1-score": [f1],
}).T

```

3. Desarrollo

3.1. Práctica 301

Usando la teoría expuesta sigue los pasos para completar la práctica:

1. Determina que características darán la máxima información y de qué forma (no uses edad)
2. Construye las variables para cada característica informativa importante
3. Construye una matriz de características con la máxima información posible
4. Construye el vector de respuesta
5. Construye un modelo basado en árboles de decisión con máximo 3 decisiones
6. Ajusta el modelo a la matriz de aprendizaje y el vector de respuesta
7. Visualiza el árbol de decisión y explica cada conclusión que toma
8. Construye el valor de predicción sobre los valores de la matriz de características
9. Obtén los valores de la matriz de confusión
10. Visualiza la matriz de confusión
11. Construye las métricas de desempeño del modelo e interprétalas
12. ¿Consideras que tiene un buen desempeño? ¿En qué sí y en qué no?

13. Crea una matriz nueva X' que contenga 3 observaciones que tu consideres con el mismo número de características que utilizaste, por ejemplo, si construiste 5 características, entonces crea una matriz de 3×5 que contenga en cada fila 5 valores posibles para cada característica
14. Crea el vector de predicción sobre la matriz X'
15. ¿Qué tan confiables son esas predicciones? Pista: Si la predicción es 0 usa la métrica de la especificidad para determinar el porcentaje de confianza, si la predicción es 1 usa la métrica de precisión, la sensibilidad y el F_1
16. Construye un modelo basado en una curva logística
17. Ajusta el modelo a la matriz de aprendizaje y el vector de respuesta
18. Construye el valor de predicción sobre los valores de la matriz de características
19. Obtén los valores de la matriz de confusión
20. Visualiza la matriz de confusión
21. Construye las métricas de desempeño del modelo e interprétalas
22. ¿Consideras que tiene un buen desempeño? ¿En qué sí y en qué no?
23. Crea el vector de predicción sobre la matriz X'
24. ¿Qué tan confiables son esas predicciones? Pista: Si la predicción es 0 usa la métrica de la especificidad para determinar el porcentaje de confianza, si la predicción es 1 usa la métrica de precisión, la sensibilidad y el F_1
25. ¿Son diferentes las predicciones del árbol de decisión a las de la curva logística? Puedes probar más de 3 para ver si algo cambia y analizar el por qué
26. Con ayuda de la IA reduce con PCA a un solo componente principal (variable c) la matriz de características X y después pide ayuda visualizar la respuesta y y la predicción y_p el componente c (deben salir dos series), tanto para el modelo por árbol de decisión como la curva logística
27. ¿Qué cambios hay las predicciones del modelo por árbol de decisión y la curva logística?