

Instituto Politécnico Nacional

Centro de Investigación en Computación (CIC)

Departamento de diplomados y extensión profesional

Curso de Machine Learning

Profesor Alan Badillo Salas

Práctica 201

Fases de un proyecto de Machine Learning - Análisis de características

Semana 2. Febrero 5, 2026.

1. Introducción

En esta práctica aprenderemos la pieza fundamental en el análisis y estructuración de un modelo de Machine Learning que consiste en el análisis y comprensión de las características involucradas en el conjunto de datos asociado al problema. Cada característica posee una naturaleza numérica o categórica y su análisis correcto permitirá determinar si los modelos de aprendizaje automático lograrán un aprendizaje de los datos o tendrán regiones de confusión al intentar ajustar o clasificar los datos.

La práctica consiste en relizar encontrar las características más importantes que nos permitan modelar una matriz de aprendizaje. Cada característica identificada será tratada de forma individual mediante un tratamiento estándar según si su naturaleza es numérica, categórica o ambas (discreta).

1.1. Objetivo general

Al finalizar la práctica, el alumno será capaz de seleccionar las características contenidas en un conjunto de datos, determinar su naturaleza numérica o categórica y aplicar un procedimiento estándar para el resumen estadístico y la visualización de datos que describen el comportamiento de cada característica.

1.2. Objetivos particulares

Al finalizar la práctica, el alumno será capaz de:

- Cargar un conjunto de datos y comprender su estructura de columnas como características de información
- Determinar si la naturaleza de los datos asociados a una columna es numérica o categórica
- Seleccionar las características principales y construir vectores y series de datos a partir de las columnas del conjunto de datos
- Determinar la naturaleza numérica o categórica de cada característica seleccionada
- Entender la importancia de no subestimar los datos faltantes o corruptos mediante técnicas de imputación
- Establecer un tratamiento estadístico para características numéricas
- Establecer un tratamiento estadístico para características categóricas
- Visualizar características numéricas
- Visualizar características categóricas

1.3. Entregables

La práctica tendrá un único entregable que consiste en un documento PDF creado en cualquier editor de texto que soporte incrustación de imágenes como Word, Excel, Power Point, Canvas o Latex y que permita la exportación o impresión al formato PDF. También se aceptarán trabajos hechos a mano siempre y cuando sean legibles y estén escaneados en formato PDF no mayor a 20mb.

Las especificaciones del *Documento de la práctica* son:

- **Portada** - Debe contener el nombre del Instituto Politécnico Nacional, el nombre del Centro de Investigación en Computación (CIC) y el Departamento de diplomados y extensión profesional, así como el logo del IPN a la izquierda y del CIC a la derecha en las esquinas superiores. También deberá decir Curso de Machine Learning y abajo el nombre del profesor, Maestro Alan Badillo Salas y el nombre del alumno (tu nombre). Después pon el nombre de la práctica (por ejemplo, Práctica 101 - Introducción al Machine Learning y las herramientas de trabajo). Hasta abajo deberá contener la fecha de la práctica o la fecha en que se realizó en el formato: Endidad del instituto. Mes día, año (por ejemplo, Ciudad de México, Febrero 1, 2026).
- **Introducción** - Explica en un párrafo de qué trata la práctica.
- **Desarrollo** - En el desarrollo deberás explicar la secuencia lógica de la práctica-
- **Resultados** - En esta sección pega las capturas de pantalla de las gráficas generadas.
- **Conclusiones** - En las conclusiones deberás resumir que se hizo en general, para qué sirve y qué aplicaciones actuales y futuras tiene (por ejemplo, ¿Se puede aplicar a tu trabajo actual? ¿Qué tipo de proyecto será interesante hacer ahora?).

1.4. Evaluación

La práctica tiene un valor de 100 puntos, de los cuales 50 son suficientes para marcarla como entregada, si tiene menos de 50 puntos no será aceptada y tendrá que ser corregida.

- **20 puntos** - La portada tiene todos los elementos
- **10 puntos** - La práctica contine una Introducción razonable
- **10 puntos** - La práctica contine la secuencia lógica de pasos completa y es razonable
- **30 puntos** - La práctica contine los resultados solicitados
- **20 puntos** - La práctica contine conclusiones razonables

- **10 puntos** - La práctica fue entregada antes de la práctica siguiente

En esta práctica se considera un mayor peso a los resultados y las conclusiones, por lo que las conclusiones deben ser precisas sobre lo que se entendió de la práctica.

2. Teoría

El problema que se desea analizar tiene como fondo un fenómeno o evento, cuando este se representa como observaciones de datos, generalmente, los registros son recopilados en forma de tabla, donde las columnas representan las características observadas y en cada cada registro y las filas continen los datos.

En un enfoque estadístico, el análisis se guía mediante variables aleatorias, que representan un vector o serie de datos que en conjunto muestran un comportamiento de cómo se comportan las observaciones.

En el enfoque del aprendizaje automático (*Machine Learning*), cada eje de datos es analizado como una característica de información, la cual tiene asociada una naturaleza cuantitativa para datos numéricos o cualitativa para datos categóricos.

Cada característica forma una dimensión de datos, y el conjunto de características permite diseñar un modelo de análisis donde se desea lograr un aprendizaje sobre el comportamiento de los datos.

El problema principal de aprendizaje consiste en seleccionar una o varias características como respuesta de las demás, a este problema le llamaremos *El problema del aprendizaje supervisado*.

Otros problemas secundarios intentarán agrupar automáticamente los datos para encontrar una nueva característica como respuesta automática de los demás o reducir la dimensionalidad para simplificar el problema, a este problema le llamaremos *El problema del aprendizaje no supervisado*.

2.1. Introducción a las características numéricas

Las características numéricas representan información espacial o temporal que asocian una medida o métrica observada, como la edad de una persona, su peso, estatura o salario.

El análisis de una característica numérica se da mediante el entendimiento de los estadísticos principales asociados a su comportamiento, como la media, la desviación estándar y varianza, el mínimo y máximo observado, el mínimo y máximo relativo a los datos y los cuantiles (percentiles, deciles y cuartiles) principalmente.

Cada estadístico será usado para interpretar el comportamiento de la distribución asociada a los datos, si esta distribución es normal la media y desviación tendrán sentido, pero si la distribución presenta sesgos o concentraciones anormales, entonces se deberá ir con cuidado.

Para estandarizar un reporte de análisis en una característica numérica calcularemos los estadísticos principales y analizaremos la distribución de los datos a través de tres visualizaciones importantes:

- **Gráfica de caja** - Mostrará el rango en el que se espera que se encuentren la mayoría de los datos y tendrá sentido si estos se concentran al rededor de un único valor (formando una única montaña o pico).
- **Gráfica de densidad** - Mostrará las concentraciones donde se agrupan los datos, si hay más de un pico o la montaña está sesgada (cargada hacia un lado izquierdo o derecho).
- **Gráfica de hoja** - Mostrará la forma de una hoja o violín advirtiendo múltiples concentraciones ocultas que podrían explicar la asociación a otra característica desconocida inicialmente (hasta que se contraste y determine si es posible conocerla).

Las gráficas verticales son usadas para entender la característica de una respuesta numérica, por ejemplo, el precio de una casa, así el rango se muestra sobre el eje Y .

Las gráficas horizontales son usadas para entender una característica informativa que es numérica, por ejemplo, el peso de una persona, así el rango se muestra sobre el eje X .

Estadísticos descriptivos de una característica numérica c_1

```
c1.describe()
```

Gráfica de densidad de la característica numérica c_1

```
c1.plot.density()
```

Gráfica de caja vertical de la característica numérica c_1

```
c1.plot.box()
```

Gráfica de caja horizontal de la característica numérica c_1

```
c1.plot.box(vert=False)
```

Gráfica de hoja vertical de la característica numérica c_1

```
seaborn.violinplot(y=c1)
```

Gráfica de hoja horizontal de la característica numérica c_1

```
seaborn.violinplot(x=c1)
```

2.2. Introducción a las características categóricas

Las características categóricas representan información relacional o ponderada que asocian una clase o categoría observada, como el sexo de una persona, el tipo de trabajo o su estado civil.

El análisis de una característica categórica se da mediante el entendimiento de los conteos principales asociados a sus categoría (clases), como la número de observaciones en cada categoría (soporte), la proporción o porcentaje de observaciones en cada categoría (probabilidad de pertenencia).

Cada conteo será usado para interpretar el comportamiento de la distribución (proporción) asociada a los datos, si el número de observaciones o soporte es alta (más de 30 observaciones en cada categoría) estas tendrán sentido, pero si el soporte es pequeño o las proporciones están muy desbalanceadas (más de 80 % en una categoría y menos del 10 % en otras) entonces debemos ir con cuidado.

Para estandarizar un reporte de análisis en una característica categórica calcularemos los conteos principales y analizaremos las proporciones de los datos a través de tres visualizaciones importantes:

- **Gráfica de barras** - Mostrará el el desbalanceo entre las categorías o clases.
- **Gráfica de pastel o dona** - Mostrará las proporciones de cada categoría y si alguna concentra más o cerca del 50 % de la información.

Además las características categóricas pueden ser usadas como segmentadores o grupos en el análisis combinado entre otras características para colorear y dividir los datos.

Conteos de una característica categórica c_2

```
c2.value_counts()
```

Proporciones de una característica categórica c_2

```
c2.value_counts(normalize=True)
```

Gráfica de barras de la característica categórica c_2

```
c2.plot.bar()
```

Gráfica de pastel de la característica categórica c_2

```
c2.plot.pie()
```

3. Desarrollo

3.1. Práctica 201

Usando la teoría expuesta sigue los pasos para completar la práctica:

1. Crea otra libreta llamada *p201.ipynb* o como te sea mejor el nombre
2. En una celda de código importa las librerías de *pandas* y *seaborn*
3. Descarga el archivo *CSV* con los datos del *Titanic*
4. Pon el archivo *titanic.csv* en la carpeta del repositorio a lado de las libretas
5. En la libreta *p201.ipynb* en una celda de código carga el *DataFrame* como la variable *titanic*
6. Muestra las primeras 10 filas del *titanic*
7. Crea la variable c_1 con la columna *Survived* (sobrevivió)
8. Crea la variable c_2 con la columna *Pclass* (clase social del boleto)
9. Crea la variable c_3 con la columna *Sex* (sexo)
10. Crea la variable c_4 con la columna *Age* (edad)
11. Crea la variable c_5 con la columna *SibSp* (familiares horizontales: hermanos y cónyuges)

12. Crea la variable c_6 con la columna *Parch* (familiares verticales: padres e hijos)
13. Crea la variable c_7 con la columna *Fare* (tarifa)
14. Crea la variable c_8 con la columna *Cabin* (cabina), en este considera determinar con la función *,isna()* si tiene o no cabina asignada (si quieres invertir la lógica usa la tilde)
15. Crea la variable c_9 con la columna *Embarked* (embarcación)
16. Genera los estadísticos descriptivos para las características numéricas c_4 , c_5 , c_6 y c_7
17. Genera las visualizaciones adecuadas para las características numéricas c_4 , c_5 , c_6 y c_7
18. Genera los conteos para las características categóricas c_1 , c_2 , c_3 , c_8 y c_9
19. Genera las visualizaciones adecuadas para las características categóricas c_1 , c_2 , c_3 , c_8 y c_9
20. Con ayuda de la IA construye una característica categórica c_{10} que contenga las clases *child* si la edad es menor o igual a 12 años, *young* si la edad es menor o igual a 20 años, *adult* si la edad es menor estrictamente a 40 años, *senior* si la edad es menor a 65 años y *old* si la edad es mayor o igual a 65 años. Nota: Las clases deben ser exclusivas, si no deseas usar la IA investiga el uso la función *.map(T)* en *Series* de *Pandas*.
21. Analiza los conteos y visualizaciones de esta nueva característica categórica c_{10} .
22. Con ayuda de la IA construye una característica categórica c_{11} que contenga las clases *0* si la persona no viajaba con ningún un familiar (suma *SibSp* y *Parch*), *1* si la persona viajaba con otro un familiar (suma *SibSp* y *Parch*) o *2+* si la persona viajaba con dos o más familiares (suma *SibSp* y *Parch*).
23. Analiza los conteos y visualizaciones de esta nueva característica categórica c_{11} .
24. Con ayuda de la IA construye una característica categórica c_{12} que contenga las clases *male-s1*, *male-s2*, *male-s3* y *female-s1*, *female-s2*, *female-s3* que combine las categorías de sexo y clase social del boleto (hombre y mujer de primera, segunda y tercera clase).
25. Analiza los conteos y visualizaciones de esta nueva característica categórica c_{12} .

26. Con ayuda de la IA construye una característica categórica c_{13} que contenga las clases *male-alive*, *male-dead* y *female-alive*, *female-dead* que combine las categorías de sexo y supervivencia.
27. Analiza los conteos y visualizaciones de esta nueva característica categórica c_{13} .
28. Con ayuda de la IA construye una característica categórica c_{14} que contenga las clases *male-alive-s1*, *male-dead-s1*, *male-alive-s2*, *male-dead-s2*, *male-alive-s3*, *male-dead-s3* y *female-alive-s1*, *female-dead-s1*, *female-alive-s2*, *female-dead-s2*, *female-alive-s3*, *female-dead-s3* que combine las categorías de sexo, supervivencia y clase social.
29. Analiza los conteos y visualizaciones de esta nueva característica categórica c_{14} .
30. Responde la pregunta ¿Cuántos hombres de primera clase sobreviven y cuántos fallecen?
31. Responde la pregunta ¿Cuántas mujeres de primera clase sobreviven y cuántos fallecen?
32. Responde la pregunta ¿Cuántos hombres de segunda clase sobreviven y cuántos fallecen?
33. Responde la pregunta ¿Cuántas mujeres de segunda clase sobreviven y cuántos fallecen?
34. Responde la pregunta ¿Cuántos hombres de tercera clase sobreviven y cuántos fallecen?
35. Responde la pregunta ¿Cuántas mujeres de tercera clase sobreviven y cuántos fallecen?
36. Responde la pregunta ¿En qué clase social sobreviven más?
37. Responde la pregunta ¿Quiénes sobreviven más, hombres o mujeres?
38. Responde la pregunta ¿Cuál es la probabilidad de que un hombre sobreviva? Pista: total de hombres que sobrevivieron entre el total de pasajeros (891)
39. Responde la pregunta ¿Cuál es la probabilidad de que siendo hombre el pasajero sobreviva? Pista: total de hombres que sobrevivieron entre el total hombres
40. Responde la pregunta ¿Cuál es la probabilidad de que una mujer sobreviva? Pista: total de mujeres que sobrevivieron entre el total de pasajeros (891)
41. Responde la pregunta ¿Cuál es la probabilidad de que siendo mujer el pasajero sobreviva? Pista: total de mujeres que sobrevivieron entre el total mujeres