

Instituto Politécnico Nacional

Centro de Investigación en Computación (CIC)

Departamento de diplomados y extensión profesional

Curso de Machine Learning

Profesor Alan Badillo Salas

Práctica 401

Regresión - Medidas de desempeño

Semana 4. Febrero 20, 2026.

1. Introducción

En esta práctica aprenderemos uno de los dos métodos más importantes del aprendizaje supervisado. La regresión permite construir modelos basados en predecir respuestas numéricas (continuas), por ejemplo, cuando se busca entender una característica que representa una medida como el costo de una casa, el peso que tendrá una persona si presenta una enfermedad o los días que tardará en venderse un producto.

La práctica consiste en construir una matriz de características para entrenar un modelo basado en la regresión lineal y otro en una máquina de soporte vectorial con grado polinomial para poder generar un vector de predicciones, la cual será comparada con el vector de respuesta real y así poder medir el desempeño del modelo para futuras predicciones.

1.1. Objetivo general

Al finalizar la práctica, el alumno será capaz de construir una matriz de características, un vector de respuesta continua y construir un modelo de regresión que prediga el comportamiento de la respuesta mediante predicciones. Así como medir el desempeño del modelo y la precisión de las predicciones para poder interpretar la confianza de dichas predicciones con distintas métricas derivadas del error calculado de la distancia del modelo a los datos (respuesta real menos respuesta de predicción).

1.2. Objetivos particulares

Al finalizar la práctica, el alumno será capaz de:

- Construir las características informativas más relevantes para poder predecir una respuesta continua.
- Construir una matriz de características que contenga la información disponible para la predicción.
- Construir un modelo de regresión basado en la regresión lineal y uno basado en soporte vectorial de kernel polinomial de segundo grado.
- Visualizar e interpretar las correlaciones entre cada característica y la respuesta
- Construir el vector de predicción sobre una matriz de características observada
- Calcular el error entre el vector de respuesta real y el vector de predicción
- Visualizar si el error se comporta de forma normal
- Calcular el MSE (*Mean Square Error - Error cuadrático medio*) y el MAE (*Mean Absolut Error - Error absoluto medio*)

- Responder preguntas sobre la predicción de ciertos valores en las características informativas y comparar la probabilidad de la respuesta real contra la predicción

1.3. Entregables

La práctica tendrá un único entregable que consiste en un documento PDF creado en cualquier editor de texto que soporte incrustación de imágenes como Word, Excel, Power Point, Canvas o Latex y que permita la exportación o impresión al formato PDF. También se aceptarán trabajos hechos a mano siempre y cuando sean legibles y estén escaneados en formato PDF no mayor a 20mb.

Las especificaciones del *Documento de la práctica* son:

- **Portada** - Debe contener el nombre del Instituto Politécnico Nacional, el nombre del Centro de Investigación en Computación (CIC) y el Departamento de diplomados y extensión profesional, así como el logo del IPN a la izquierda y del CIC a la derecha en las esquinas superiores. También deberá decir Curso de Machine Learning y abajo el nombre del profesor, Maestro Alan Badillo Salas y el nombre del alumno (tu nombre). Después pon el nombre de la práctica (por ejemplo, Práctica 101 - Introducción al Machine Learning y las herramientas de trabajo). Hasta abajo deberá contener la fecha de la práctica o la fecha en que se realizó en el formato: Entidad del instituto. Mes día, año (por ejemplo, Ciudad de México, Febrero 1, 2026).
- **Introducción** - Explica en un párrafo de qué trata la práctica.
- **Desarrollo** - En el desarrollo deberás explicar la secuencia lógica de la práctica-
- **Resultados** - En esta sección pega las capturas de pantalla de las gráficas generadas.
- **Conclusiones** - En las conclusiones deberás resumir que se hizo en general, para qué sirve y qué aplicaciones actuales y futuras tiene (por ejemplo, ¿Se puede aplicar a tu trabajo actual? ¿Qué tipo de proyecto será interesante hacer ahora?).

1.4. Evaluación

La práctica tiene un valor de 100 puntos, de los cuales 50 son suficientes para marcarla como entregada, si tiene menos de 50 puntos no será aceptada y tendrá que ser corregida.

- **20 puntos** - La portada tiene todos los elementos
- **10 puntos** - La práctica contine una Introducción razonable

- **10 puntos** - La práctica contine la secuencia lógica de pasos completa y es razonable
- **30 puntos** - La práctica contine los resultados solicitados
- **20 puntos** - La práctica contine conclusiones razonables
- **10 puntos** - La práctica fue entregada antes de la práctica siguiente

En esta práctica se considera un mayor peso a los resultados y las conclusiones, por lo que las conclusiones deben ser precisas sobre lo que se entendió de la práctica.

2. Teoría

El problema de la regresión es parte de *El problema del aprendizaje no supervisado*. En la regresión se exige que la respuesta sea continua, para determinar una curva, plano, hiperplano, superficie o variedad que se ajuste lo mejor posible a los datos, la forma más simple es suponer un modelo lineal, donde un hiperplano será ajustado para pasar por todas las respuestas lo más cercano posible, en una dimensión se ve como una recta que predice los valores de la respuesta en el eje Y con la única característica como eje X , con , en dos dimensiones como un plano con la respuesta orientada hacia arriba y las dos característica en los ejes X y Z .

El modelo lineal generalizado se ve como:

$$y = \beta_0 + \beta_1 \cdot x_1 + \dots + \beta_k \cdot x_k$$

Para la observación j -ésima podemos ver la respuesta y_j dependiente de las características $x_1^{(j)}, \dots, x_k^{(j)}$, es decir, cada observación representa una respuesta:

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1^{(1)} + \dots + \beta_k \cdot x_k^{(1)} \\ &\dots \\ y_j &= \beta_0 + \beta_1 \cdot x_1^{(j)} + \dots + \beta_k \cdot x_k^{(j)} \\ &\dots \\ y_n &= \beta_0 + \beta_1 \cdot x_1^{(n)} + \dots + \beta_k \cdot x_k^{(n)} \end{aligned}$$

Esto significa que para las n observaciones tendremos n ecuaciones lineales simultáneas, que podremos llevar a una forma vectorial y matricial:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_j \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_1^{(1)} & \dots & x_k^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(j)} & \dots & x_k^{(j)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & \dots & x_k^{(n)} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

O de forma compacta lo podemos expresar como la matriz de covariables (la matriz de características incluyendo el vector de unos) de tal manera que el vector β representa los parámetros de ajuste o pesos a encontrar, también llamados los coeficientes de regresión:

$$\mathbf{y} = \mathbf{X}\beta$$

Donde $\mathbf{y}$ se considera el vector de respuesta, $\mathbf{X}$ la matriz de covariables y β los coeficientes de regresión.

Entonces, podemos plantear el problema como un sistema lineal donde al encontrar el vector de parámetros de ajuste β , tendremos la mejor aproximación lineal que determinará el modelo de menor error lineal, mediante las ecuaciones normales, haciendo uso de algunas sustituciones algebraicas:

$$\begin{aligned}\mathbf{y} &= \mathbf{X}\beta \\ \mathbf{X}^\top \mathbf{y} &= \mathbf{X}^\top \mathbf{X}\beta \\ \mathbf{X}^\top \mathbf{X}\beta &= \mathbf{X}^\top \mathbf{y}\end{aligned}$$

Llegando finalmente a:

$$\beta = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Donde, el sistema podrá ser resuelto si $(\mathbf{X}^\top \mathbf{X})^{-1}$ está determinada, es decir, si la matriz $(\mathbf{X}^\top \mathbf{X})^{-1}$ que es cuadrada y positiva definida (se puede demostrar) no tiene determinante cero.

Esta última condición nos lleva a un problema de multicolinealidad, que afecta mucho si la matriz $(\mathbf{X}^\top \mathbf{X})^{-1}$ tiene determinante casi cero debido a la posible combinación lineal entre las características, es decir, si dos o más características están altamente correlacionadas entre sí. En dicho caso, deberemos aplicar estrategias para reducir la multicolinealidad como transformaciones Box-Cox o algunas otras.

Además, debemos considerar que para que este modelo lineal tenga sentido, el error entre el modelo y la observación real se deberá comportar de forma normal (debe tener una distribución normal), para que las bandas que capturan el modelo y los datos garanticen que la probabilidad de que estos se alejan del modelo es cada vez menor (de forma exponencial) y prácticamente el modelo captura la mayoría de los datos salvo una desviación estándar constante.

Es decir, si:

$$\epsilon = \mathbf{y}_{\text{real}} - \mathbf{y}_{\text{prediccion}}$$

Entonces, $\epsilon \sim \text{Normal}(0, \sigma^2)$ el error se comporta de forma normal con media cero (un error cercano a cero).

Así, podemos plantear el modelo lineal como un problema de optimización donde

SSE representará la suma de errores cuadráticos:

$$\min SSE = (\mathbf{y}_{\text{real}} - \mathbf{y}_{\text{prediccion}})(\mathbf{y}_{\text{real}} - \mathbf{y}_{\text{prediccion}})^{\top}$$

O de forma desarrollada:

$$\begin{aligned} \min_{\beta \in \mathbb{R}^{k+1}} SSE &= (\mathbf{y}_{\text{real}} - \mathbf{X}\beta)(\mathbf{y}_{\text{real}} - \mathbf{X}\beta)^{\top} \\ &= \sum_{j=1}^n (\mathbf{y}_j - \beta x^{(j)})^2 \end{aligned}$$

Donde $x^{(j)}$ es el vector de características para la observación j -ésima incluyendo $x_0^{(j)} = 1$ asociado al bias.

Con esta métrica de error, podemos medir dos métricas (MSE y MAE) importantes y una métrica derivada (RMSE):

- **MSE** - El promedio de la suma errores cuadráticos $MSE = \frac{1}{n} SSE = \frac{1}{n} \sum_{j=1}^n (\mathbf{y}_j - \beta x^{(j)})^2$.
- **RMSE** - La raíz cuadrada del promedio de la suma errores cuadráticos $RMSE = \sqrt{MSE}$.
- **MAE** - El promedio de la suma errores absolutos $MSE = \frac{1}{n} SSE = \frac{1}{n} \sum_{j=1}^n |\mathbf{y}_j - \beta x^{(j)}|$.

Donde el MSE representa cómo se aleja cuadráticamente el modelo ideal de los datos y está asociada al segundo momento estadístico y la varianza, mientras que el $RMSE$ se asocia con el primer momento estadístico y la desviación estándar. Y el MAE representa cómo se aleja en términos absolutos en las mismas unidades que la respuesta.

Por ejemplo, si la respuesta es el precio de una casa dadas sus características, entonces, un $MAE = 12,000$ representará una diferencia absoluta promedio de \$12,000 pesos para una observación cualquiera, entre lo que predice el modelo y los datos reales.

Interpretación de las betas

Las betas o el vector β representa los coeficientes de regresión, estos son pesos que determina el modelo sobre la influencia de cada característica como aportación de la respuesta.

Una β_i cercana a cero significará que la característica x_i asociada al modelo, tiene baja influencia, pero depende de la escala de la característica.

Entonces, $\beta_i \cdot \overline{x_i}$ determina cuánto aporta en promedio la característica ponderada hacia la respuesta, por ejemplo, si x_3 es la edad de una persona y $\overline{x_i} = 26$

la edad promedio de una persona es de 26 años, y $\beta_3 = 10$, entonces $\beta_i \cdot \bar{x}_i = 10 \cdot 26 = 260$ significa que la edad aporta una cantidad de 260 a la respuesta. Si la respuesta fueran los días que tarda en comprar unos zapatos, entonces, una persona promedio aportará 260 días a la respuesta, sin embargo, otras características podrían aportar negativamente, por ejemplo, una característica x_8 que sea el número de hijos podría tener una $\beta_8 = -33$ que significaría que con 3 hijos disminuye casi 100 días que la persona compre unos zapatos en la tienda (para alguno de sus hijos).

Así cada beta aportará positivamente o negativamente la información de las características, haciendo que al final el modelo sume todas las aportaciones para dar la respuesta que mejor se ajusta a los datos, aunque si el error MAE es muy alto, entonces, no será muy fiable el ajuste lineal, pero si este falla por pocas unidades de la respuesta, entonces la predicción será muy fiable.

Construcción del vector de respuesta

```
y = <dataframe>["<caracteristica de respuesta>"]
```

Construcción de la matriz de covariables

Para el modelo lineal construido a mano, debemos utilizar la matriz de covariables en lugar de la matriz de características, esta matriz es la misma pero tiene una columna con valores de 1 a lo largo de todas las observaciones usado como primera columna, para poder determinar el bias o β_0 del modelo lineal.

Supongamos que tenemos las características informativas $x_1, x_2, \dots, x_k$, entonces la matriz $X = [1|x_1|x_2|\dots|x_k]$ representa matriz de covariables.

```
n = len(y)
```

```
X = pandas.DataFrame([numpy.ones(n), x1, x2, ..., xk]).T
```

Modelo de lineal (a mano)

```
betas = numpy.linalg.inv(X.T.dot(X)).dot(X.T.dot(y))
```

Predecir el vector de respuesta

```
yp = X.dot(betas)
```

Calcular el error entre la respuesta real y la predicción

```
e = y - yp
```

Graficar el error para determinar si tiene un comportamiento normal

```
seaborn.kdeplot(x = e) # seaborn.kdeplot(x = y - yp)
```

Calcular las métricas derivadas del error

```
SSE = e.dot(e)

MSE = SSE / n

RMSE = MSE ** 0.5

MAE = e.abs().sum() / n

pandas.DataFrame({
    "SSE": [SSE],
    "MSE": [MSE],
    "RMSE": [RMSE],
    "MAE": [MAE],
}).T
```

Modelo de regresión por soporte vectorial con kernel polinomial de grado cuadrático

```
from sklearn.svm import SVR

modelo = SVR(kernel="poly", degree=2)
```

Ajustar el modelo de regresión a los datos observados

```
# IMPORTANTE: Aqui usamos la matriz de caracteristicas sin bias

X = pandas.DataFrame([x1, x2, ..., xk]).T

modelo.fit(X, y)
```

Construir el vector de predicción del modelo

```
yp = modelo.predict(X)
```

3. Desarrollo

3.1. Práctica 401

Usando la teoría expuesta sigue los pasos para completar la práctica:

1. Carga un conjunto de datos como el de las *casas.csv*
2. Determina que características darán la máxima información y de qué forma
3. Construye las variables para cada característica informativa importante
4. Construye una matriz de covariables con la máxima información posible
5. Construye el vector de respuesta (la respuesta será continua)
6. Construye un modelo lineal manual y encuentra las betas
7. Analiza el valor de $\beta_0, \beta_1, \dots, \beta_k$
8. Analiza el valor de $\beta_1 \cdot \bar{x}_1, \dots, \beta_k \cdot \bar{x}_k$. Pista: usa $\bar{x}_i = x_i.mean()$
9. ¿Cuál es la característica que en promedio aporta más información? Ya sea positivamente o negativamente
10. ¿Cuál es la característica que en promedio aporta menos información? Es decir, que el valor del producto promedio sea cercano a cero
11. Si la primera característica aumenta una unidad, ¿Cuánto aumenta o disminuye el valor de la respuesta?. Pista: es el valor directo de la beta.
12. Construye el vector de predicción
13. Calcula el error entre el vector de respuesta y el vector de predicción
14. Visualiza la distribución del error y explica si este se comporta de forma normal
15. Visualiza la primera característica contra la respuesta en forma de puntos
16. Con ayuda de la IA aumenta la recta de predicción a la gráfica anterior, fijando las demás características en su valor promedio
17. Con ayuda de la IA aumenta diferentes rectas fijando ahora los cuartiles Q_1 y Q_3 de cada característica restante. Nota: saldrán un montón de rectas, y algunos ciclos *for*. Si tienes dudas intenta darle todos estos puntos a la IA para que interprete bien lo que se busca (una recta por cada combinación de cuartil bajo y alto para cada característica restante). Se usará solamente la primera característica como punto de apoyo.